

FACULTAD DE CIENCIAS EXACTAS, INGENIERÍA Y AGRIMENSURA ESCUELA DE CIENCIAS EXACTAS Y NATURALES DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN COMPILADORES

Apunte de cátedra: Una máquina virtual

En el capítulo anterior presentamos la máquina abstracta CEK, que implementa una estrategia de reducción CBV sobre los términos de FD4 de manera (más) eficiente. Ahora, en vez de quedarnos con la sintaxis de FD4 e interpretarla, compilaremos los programas al código de una máquina *virtual* llamada BVM, de nivel más bajo, en donde el "control" ya no es un término FD4, sino una secuencia de instrucciones llamada comúnmente "bytecode". Implementaremos la compilación de FD4 a bytecode y también la máquina virtual que lo ejecuta, en Haskell.

Terminología. Llamamos "máquina abstracta" a una descripción abstracta de una máquina que opera sobre sintaxis, es decir sobre los términos de FD4 o el lenguaje de interés. Por el contrario, una máquina virtual opera sobre un lenguaje de bajo nivel propio, compuesto de instrucciones. Esta terminología es la que usaremos en la cátedra aunque, como mucha terminología en el estudio de lenguajes de programación, no es universalmente compartida, .

Nuestra máquina virtual será de la familia de máquinas de pila, en donde la ejecución mantiene una pila con los valores computados. Algunas operaciones agregan valores a la pila y algunas los consumen. En la BVM llevaremos también un entorno con los valores de cada variable local, muy similarmente a la máquina CEK, y también usando una noción similar a los índices de de Bruijn.

Un bytecode no es más que una secuencia de enteros (de un tamaño fijo), representando tanto a las instrucciones, mediante códigos de operación (opcode), como a los argumentos de algunas de ellas. El proceso comienza con un término e que se compila via una función $\mathcal{C}(-)$ (detallada abajo) para obtener bytecode. Luego, ese bytecode puede ejecutarse en la BVM.

1. Forma de la Máquina

Los estados de la máquina son de la forma $\langle c \mid e \mid s \rangle$, donde:

- c es una secuencia de instrucciones, la cual se recorre de manera mayormente secuencial. Esta secuencia nunca se modifica, sólo se recorre. A veces conviene pensar que c es un puntero a una secuencia (read-only) de instrucciones.
- ullet e es un entorno: una lista de valores donde el primer elemento contiene el valor de la variable 0, y así sucesivamente.
- ullet s es una pila de valores, que pueden ser de distintos tipos, detallados más adelante. Algunas instrucciones agregan y/o consumen elementos de la pila, pero siempre cerca del "tope".

Los valores de la máquina pueden ser de los siguientes tipos:

- \blacksquare Naturales: representados con n,
- Clausuras: un par de un entorno y un puntero a código (e,c), o
- Direcciones de retorno: también son un par de entorno y puntero a código $(e,c)_{RA}$.

En **ningún caso** la máquina *observa* el tipo de un valor: las acciones de la máquina están solamente determinadas por las instrucciones. De hecho, cuando implementemos esta máquina en un lenguaje de nivel más bajo, vamos a usar uniones no-etiquetadas para los valores¹. Si una instrucción X espera (por ejemplo) un natural en la pila pero en realidad hay una clausura, *se va a ejecutar igual* y tener un comportamiento no definido. Claramente, los términos bien tipados deben compilar a código que nunca invoca comportamiento no definido.

La distinción entre los distintos tipos de valor es entonces sólo tipográfica, para hacer la lectura de este documento más amigable.

El estado inicial de la máquina es de la forma $\langle c \mid \epsilon \mid \epsilon \rangle$, es decir un puntero a código con entorno y pila vacíos.

Apunte de cátedra: Una máquina virtual

 $^{^{1}}$ En Haskell, un tipo data Either a b = Left a | Right b es una unión etiquetada de a y b, que permite distinguir en cual caso se está dado un valor del tipo. En contraste, las union de C son no-etiquetadas.

2. Intuición: Fragmento Aritmético

Vamos a considerar primero el fragmento aritmético de FD4: sin funciones, sólo enteros y operadores binarios. La idea es que las constantes enteras se implementan como una instrucción CONST n que agrega al elemento n a la cima de la pila. Las instrucciones ADD y SUB operan sobre los dos elementos en la cima de la pila. Al ser así, las instrucciones aparecen luego de las instrucciones que agregan el valor necesario a la pila.

Entonces, la etapa de compilación es:

```
 \begin{array}{l} \mathcal{C}(n) = \text{CONST } n \\ \mathcal{C}(e+e') = \mathcal{C}(e); \; \mathcal{C}(e'); \; \text{ADD} \\ \mathcal{C}(e-e') = \mathcal{C}(e); \; \mathcal{C}(e'); \; \text{SUB} \end{array}
```

Mientras que las reglas relevantes de la máquina son:

(con el abuso de notación que 0-1=0). De esta manera, si compilamos 2+(3-1), obtenemos el bytecode:

```
CONST 2; CONST 3; CONST 1; SUB; ADD;
```

y al evaluarlo en la máquina obtenemos la traza:

para cualquier valor de c, e y s. Como regla general, el ejecutar C(t) para una expresión t tiene el efecto de pushear el resultado de evaluar t en la pila. Los operadores que esperan argumentos esperan encontrarlos en el tope de la pila.

3. Compilando λ -términos

Con esta intuición sobre el manejo de la pila, tornamos la atención a los λ -términos. El acceso a una variable local se compila como una instrucción ACCESS que busca su valor en el entorno. La aplicación se compila como la evaluación secuencial de la función y su argumento, que pusheará dos elementos a la pila, y una instrucción CALL que efectua la llamada a función. Para soportar esto, nuestra compilación de funciones inserta una instrucción RETURN en el cuerpo de las funciones, para que al terminar de evaluar el cuerpo se vuelva al código que la llamó 2 .

```
 \begin{array}{ll} \mathcal{C}(v_i) = \texttt{ACCESS} \ i \\ \mathcal{C}(fe) = \mathcal{C}(f); \ \mathcal{C}(e); \ \texttt{CALL} \\ \mathcal{C}(\lambda t) = \texttt{FUNCTION}(\mathcal{C}(t); \ \texttt{RETURN}) \end{array}
```

donde v_i representa a la variable de de Bruijn i.

La instrucción FUNCTION, como está escrita aquí arriba, contiene un "sub"-código y rompe con la idea de que el código es una secuencia de instrucciones. Luego veremos como codificarla de manera "serializada". Por ahora, podemos pensar que es una instrucción que puede contener bytecode dentro.

La idea aquí es que una instrucción FUNCTION agregará una clausura a la pila con un entorno y un puntero al cuerpo de la función. La instrucción CALL, tomará ese entorno y código de la pila, extenderá el entorno con el argumento de la función y saltará al cuerpo de la función. Antes de saltar, sin embargo, guardará una dirección de retorno en la pila para que sea usada por la instrucción RETURN. La instrucción RETURN salta incondicionalmente a

²Notar la diferencia con la máquina CEK: al llegar a un valor en CEK debíamos inspeccionar la pila para "retornar" a otra parte de la evaluación, según el tipo de nodo. Aquí toda esa complejidad se maneja durante la compilación, y la máquina salta "a ciegas".

la dirección de retorno en la pila, descartando el entorno y el puntero actual. La regla de RETURN toma la dirección del segundo elemento de la pila, ya que en la cima está el valor resultado de evaluar el cuerpo, que permanece en la pila.

Notar una diferencia conceptual entre las clausuras y las direcciones de retorno: las primeras requieren agregar un valor a su entorno (porque representan funciones sin aplicar), pero no así las segundas.

Veamos un pequeño ejemplo, la evaluación del término $(\lambda x.x + 4)$ 10 dentro de algún contexto. El bytecode generado es:

```
FUNCTION(ACCESS 0; CONST 4; ADD; RETURN); CONST 10; CALL; k
```

donde k, posiblemente no vacío, es la continuación del bytecode generada por otras partes del programa. La traza que genera este código es (abreviamos con B el cuerpo de la clausura):

Como es de esperar, llegamos a la continuación del código habiendo agregado el valor 14 en la pila.

4. Let-Bindings Internos

Consideremos la compilación de let $x : \tau = e_1$ in e_2 . Intuitivamente, sólo tenemos que evaluar e_1 , y luego evaluar e_2 con el valor de e_1 agregado al entorno. Para terminar, debemos quitar este valor del entorno para no afectar a las instrucciones que siguen ("olvidando" el valor al igual que lo haría el RETURN).

Para hacer esto, introducimos dos instrucciones SHIFT y DROP, y las usamos para compilar los lets.

$$\mathcal{C}(\texttt{let } x = e_1 \texttt{ in } e_2) \ = \ \mathcal{C}(e_1); \texttt{ SHIFT}; \ \mathcal{C}(e_2); \texttt{ DROP}$$

$$\langle \texttt{SHIFT}; \ c \mid e \mid v : s \rangle \longrightarrow \langle c \mid v : e \mid s \rangle$$

$$\langle \texttt{DROP}; \ c \mid v : e \mid s \rangle \longrightarrow \langle c \mid e \mid s \rangle$$

5. Imprimiendo valores

Hasta ahora, la máquina no tiene ningún efecto salvo consumir electricidad. Para observar información sobre naturales utilizamos la instrucción PRINTN que imprime el valor (natural) al tope de la pila, que se ejecuta via la regla:

$$\left\langle \mathtt{PRINTN};\; c \mid e \mid n:s \right\rangle \xrightarrow{n} \left\langle c \mid e \mid n:s \right\rangle$$

es decir: no tiene efecto en el estado de la máquina, pero imprime el entero n por la consola al ejecutarse.

La máquina también puede imprimir cadenas estáticas (es decir que las cadenas a imprimir ya son conocidas antes de la ejecución). Para esto utilizamos la instrucción PRINT. La instrucción PRINT imprime la cadena que sigue a la instrucción PRINT y que termina en NULL.

$$\left\langle \mathtt{PRINT}; \ x_0; \ x_1; \ \dots \ x_n; \ \mathtt{NULL}; \ c \mid e \mid s \right\rangle \overset{x_0 x_1 \dots x_n}{\longrightarrow} \left\langle c \mid e \mid s \right\rangle$$

Cada x_i es un natural correspondiente a un caracter según Unicode. Por ejemplo al caracter **a** le corresponde el 97, a la $\tilde{\mathbf{n}}$ el 241, y a nuestra querida letra λ el 955.

Con estas instrucciones podemos compilar un comando print.

$$\mathcal{C}(\mathsf{print}\ "c_1c_2\dots c_n"\ t) = \mathsf{PRINT};\ \mathrm{ord}(c_1);\ \mathrm{ord}(c_2);\ \dots;\ \mathrm{ord}(c_n);\ \mathsf{NULL};\ \mathcal{C}(t);\ \mathsf{PRINTN}$$

donde ord(c) es el natural correspondiente al caracter c.

6. Finalizando la ejecución

Para finalizar una ejecución, tenemos una instrucción STOP, que detiene la máquina. Por ejemplo, entonces, para imprimir el resultado de evaluar una expresión e, podemos generar el bytecode C(e); PRINTN; STOP y ejecutarlo.

Con esto, ya tenemos casi todo el núcleo de FD4 implementado. Sin embargo, brillan por su ausencia las funciones recursivas.

7. Fixpoints: Poniéndole un Moño a la Recursión

Advertencia: naturalmente, esta sección puede llevar algunas iteraciones para ser entendida por completo. Una forma de compilar un fixpoint es introducir un nuevo tipo de valor para representar las clausuras de funciones recursivas:

$$(e,c)_{FIX}$$

y agregar el siguiente caso a CALL:

(ERRÓNEA)
$$\langle \text{CALL}; c \mid e \mid v : (e_f, c_f)_{\text{FIX}} : s \rangle \longrightarrow \langle c_f \mid v : (e_f, c_f)_{\text{FIX}} : e_f \mid (e, c)_{RA} : s \rangle$$

pero esto implica llevar etiquetas! Al llegar a un CALL, tenemos que distinguir si la función en la pila es recursiva, para decidir si pasarle su binding recursivo o no. Notar que este chequeo $debe\ ser\ dinámico$, no hay forma de decidir estáticamente en un llamada fe si f evalua a una función recursiva o no³. Entonces, esta regla atenta contra nuestro objetivo de ejecución eficiente.

Por suerte, no todo está perdido, y podemos tratar a las funciones recursivas y no recursivas uniformemente, como de hecho ocurre en los lenguajes reales. La idea es atar el nudo al momento de crear una clausura para una función recursiva, y luego usar CALL sin modificar. Si miramos la regla (ERRÓNEA) de arriba, el binding recursivo $(e_f, c_f)_{\text{FIX}}$ no depende de v, ni de ninguna componente de la máquina en ese momento, por lo que podemos "hacerlo antes", al momento de crear la clausura. Entonces, vamos a compilar las funciones recursivas con un marcador distinto (recordar que e tiene dos índices libres):

$$C(fix. e) = FIXPOINT(C(e); RETURN)$$

Hasta aquí, es análogo a las funciones no recursivas. La diferencia está al ejecutar esta instrucción. La regla es:

$$\langle \texttt{FIXPOINT}(c_f); c \mid e \mid s \rangle \longrightarrow \langle c \mid e \mid (e_{\text{fix}}, c_f) : s \rangle$$

donde e_{fix} extiende al entorno e con un valor más, el binding recursivo para la función, lo que permite que podamos llamarla como una función normal. Es decir, es de la forma:

$$e_{\text{fix}} = (e_1, c_f) : e$$

pero, ¿qué es e_1 ? Debe ser un entorno que permita llamar a c_f como una función normal. Entonces, también debe ser una extensión del entorno e, donde el primer valor es el binding recursivo de f, es decir

$$e_1 = (e_2, c_f) : e$$

y entonces,

$$e_{\text{fix}} = ((e_2, c_f) : e_1, c_f) : e$$

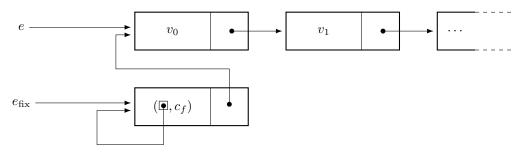
³Al menos, sin complicar el sistema de tipos...

pero, estamos en el mismo problema de necesitar un e_2 . Es claro que iterando este proceso no vamos a conseguir un entorno viable, pero sí existe una solución engañosamente simple:

$$e_{\text{fix}} = (e_{\text{fix}}, c_f) : e$$

Si podemos formar un entorno e_{fix} recursivo, donde el entorno del primer valor de e_{fix} es exactamente e_{fix} , entonces podemos implementar esta regla, y de manera eficiente. El generar estructuras de datos recursivas es permitido por algunos lenguajes, y Haskell es uno de ellos⁴. De hecho, la última ecuación es (módulo sintaxis) una definición válida en Haskell!

Para entender lo que pasa concretamente en la memoria, el siguiente diagrama puede ayudar. Antes de atar el nudo, e apunta a un entorno, que es una lista enlazada de valores. Para extenderlo, creamos un nodo, apuntado por $e_{\rm fix}$. El sucesor de $e_{\rm fix}$, es decir el nodo siguiente en la lista, es simplemente e. Ahora bien, el valor que contiene el primer nodo de $e_{\rm fix}$ es una clasura: un par entorno-código. El código es c_f , y el entorno es el mismo $e_{\rm fix}$.



Si programáramos en (por ejemplo) C, tendríamos que modificar unos punteros para generar la estructura cíclica del diagrama, lo que también es perfectamente implementable (aunque no tan elegantemente).

8. Compilando Programas

Otra parte de FD4 que omitimos arriba son las variables libres, que apuntan a definiciones "top-level" (i.e. declaraciones). Sólo vamos a soportar la compilación de programas (es decir, archivos) enteros, y no nos interesa mucho la compilación interactiva a bytecode (se puede hacer perfectamente, pero el manejo del entorno es engorroso). Dada la compilación de let-bindings vista anteriormente, podemos pensar que un programa

$$P=egin{array}{l} ext{let} \ v_1=e_1 \ ext{let} \ v_2=e_2 \ \dots \ ext{let} \ v_n=e_n \end{array}$$

puede ser traducido al término:

$$ext{let } v_1 = e_1 ext{ in } \ ext{let } v_2 = e_2 ext{ in } \ ext{} \cdots \ ext{let } v_n = e_n ext{ in } \ ext{} v_n$$

donde sólo nos interesa el resultado de la última definición top-level. Entonces, para compilar un programa P a bytecode, generamos el siguiente código:

$$C(T_P)$$
; PRINTN; STOP

que en efecto evalua todas las declaraciones top-level en orden, imprime el valor de la última (que debe ser de tipo \mathbb{N} , o se levanta un error de compilación) y detiene la máquina.

⁴Un excelente ejemplo de esto es la lista recursiva let fibs = 0:1:zipWith (+) fibs (tail fibs), que computa el n-ésimo número de Fibonacci... jen tiempo lineal!

9. Representación Concreta e Implementación

- Representaremos un Bytecode simplemente como [Int]. Para escribirlo a un archivo, necesitamos un formato binario bien definido. Usaremos una cadena de enteros de longitud fija (usamos 32 bits, formato little endian)⁵.
- Cada instrucción (ACCESS, CALL, etc) es representada por su opcode. Por ello, salvo por su posición son indistinguibles de otros datos en el bytecode. Los valores concretos de los opcodes son irrelevantes.
- Las instrucciones que tienen un argumento, como ACCESS, son representadas por dos enteros, uno para el opcode y uno para su argumento. La máquina debería comportarse acordemente, avanzando dos posiciones de código en estos casos.
- La parte en la que fuimos un poco abstractos aún es con las clausuras: ¿cómo representamos FUNCTION(e)? Una forma es llevando la longitud de e para poder saltarla. Por ejemplo, si el opcode de FUNCTION es 0x42 y e es el bytecode [10,11,12,13,14], representamos FUNCTION(e) con [0x42, 5, 10, 11, 12, 13 14]. Al llegar al 0x42, la máquina consume la longitud (5), guarda el puntero a e (apuntando al 10), y salta 5 posiciones hacia adelante.
- En Haskell, vamos a usar un tipo algebraico data para representar a los valores.

```
data Val = I Int | Fun Env Bytecode | RA Env Bytecode
```

Repetimos: la máquina nunca debe analizar el constructor de este tipo para tomar una decisión. Si la instrucción es ADD, y los dos valores al tope de la pila no son I, la máquina aborta con un error. Si fuera una implementación sin etiquetas, tomaría lo que sea que esté en la pila y lo interpretaría como un entero. Los casos de Fun y RA pueden unirse en un solo constructor: no debería llevar a confusión en la máquina, pero es menos claro al leer el código.

■ En vez de tener FUNCTION y FIXPOINT, tomaremos otro camino usaremos solo FUNCTION y agregaremos una operación FIX, compilando los fixpoints a:

$$C(fix. e) = FUNCTION(C(e); RETURN); FIX$$

La ejecución de FIX toma la clausura de la pila y le ata el nudo recursivo como en la $\S7$. Esto permite reusar un poco de código, pero implica que (brevemente) se rompa una invariante y exista una clausura mal formada en la pila (porque e tiene dos índices libres).

■ Una nota sobre eficiencia: hay que notar que cada vez que "guardamos" un bytecode o un entorno durante la ejecución, esto es solamente la copia de un puntero, y por lo tanto se hace en O(1). Esto es posible ya que los entornos son persistentes, y sólo existe una pila durante la ejecución. Una ineficiencia inherente de usar listas es que el "saltear" n instrucciones cuesta O(n), pero podremos evitarlo en el próximo capítulo.

10. Bytecode en el $Mundo Real^{TM}$

Las máquinas virtuales de pila no son para nada un ejercicio teórico: muchos lenguajes existentes y muy usados las usan para su compilación a bytecode. La principal ventaja de usar una máquina virtual es poder definir una arquitectura que viene a ocupar el lugar de un lenguaje intermedio. Al hacer esto, podemos compilar distintos lenguajes a la misma máquina, e implementar la máquina en distintas arquitecturas con un trabajo acotado. Por otro lado, la compilación es usualmente más rápido que si fuera a código nativo.

A saber, la familia Java, los lenguajes .NET, OCaml y Python usan máquinas virtuales de pila. Todas son máquinas virtuales de pila, aunque la JVM también tiene una noción de registros. Tanto la JVM como la CLR son apuntadas por *muchos* lenguajes distintos, economizando la compilación via una máquina común, y permitiendo una interoperación fluida entre distintos lenguajes. OCaml y Python también usan máquinas de pila para su compilación: OCaml lo hace para tener código portable entre arquitecturas, y Python para ganar algo de velocidad contra el código puramente interpretado.

⁵Ignoramos problemas de overflow/underflow aquí, mientras estemos lejos de 2³¹, no habrá problema.

La JVM implementa una técnica conocida como just in time compilation (JIT). Esencialmente, cuando la máquina está por ejecutar un bloque de código por primera vez, hace una etapa de compilación a código nativo, lo recuerda, y luego lo ejecuta. De esta forma si bien el bytecode es totalmente portable, se puede aprovechar al completo el procesador al evaluarlo (pagando el precio de la compilación, que se amortiza rápidamente).

11. Implementación

Asegurarse de usar la última versión del repositorio del archivo Byecompile.hs.

11.1. Procesando opciones de línea de comandos

En esta implementación del compilador usaremos la línea de comandos. Al correr el compilador con la opción 'stack run -- --bytecompile file.fd4' deben generar un archivo file.byte con el bytecode. Similarmente, al correr con 'stack run -- --runVM file.byte', debe ejecutar el bytecode con la máquina virtual.

Las opciones de línea de comandos pueden ser muchas veces resueltas con un parser simple, pero es conveniente usar una librería ya que esto facilita mantener la documentación sincronizada cuando se hacen cambios. En el Main.hs ya está todo listo para usar la librería optparse-applicative. Esta librería no está basada en mónadas sino en funtores aplicativos [1], lo que le permite analizar la estructura de los parsers y generar automáticamente a partir del parser una ayuda como la siguiente:

```
Compilador de FD4 de la materia Compiladores 2021
```

```
Usage: compiladores-exe [(-t|--typecheck) | (-k|--interactiveCEK) |
                          (-m|--bytecompile) | (-r|--runVM) |
                          (-i|--interactive)] [FILES...]
 Compilador de FD4
Available options:
  -t,--typecheck
                           Chequear tipos e imprimir el término
  -k,--interactiveCEK
                           Ejecutar interactivamente en la CEK
  -m,--bytecompile
                           Compilar a la BVM
  -r,--runVM
                           Ejecutar bytecode en la BVM
  -i,--interactive
                           Ejecutar en forma interactiva
 -h,--help
                           Show this help text
```

11.2. Serializando estructuras

En el archivo Bytecompile.hs encontrarán las definiciones para codificar y decodificar secuencias de enteros a un archivo. Pueden usar este archivo de plantilla para escribir el compilador a bytecode y la ejecución de la máquina virtual. En el mismo se define el tipo para bytecode simplemente como una lista de enteros.

```
type Bytecode = [Int]
```

Las funciones que restan escribir son:

■ bc :: MonadFD4 m => Term -> m Bytecode Compila un término a bytecode.

bytecompileModule :: MonadFD4 m => Module -> m Bytecode

- Usa la función be para compilar un módulo, utilizando la técnica descripta en la sección 8. Notar que aquí es necesario transformar variables Global en variables Free para poder usar nuestros dispositivos de manejo de variables ligadas.
- runBC :: MonadFD4 m => Bytecode -> m ()
 Implementa la BVM, ejecutando bytecode.

11.3 Tareas REFERENCIAS

Ya se proveen funciones bcWrite :: Bytecode ->FilePath ->IO () para codificar secuencias de enteros Bytecode y escribirlas en un archivo, y bcRead :: FilePath ->IO Bytecode para leer de un archivo y decodificar a Bytecode.

Para codificar y decodificar cadenas utilizar las funciones ord y chr del módulo Data. Char.

11.3. Tareas

- a) Implementar la compilación a bytecode y máquina virtual en Haskell, usando el esqueleto provisto. Dado que las instrucciones PRINT y PRINTN imprimen a la consola, la función que ejecuta la máquina debe estar en MonadFD4.
- b) Proponer e implementar un esquema de compilación y ejecución para ifz. Pueden agregarse nuevas instrucciones a la máquina.

Referencias

[1] Conor Mcbride and Ross Paterson. Applicative programming with effects. *J. Funct. Program.*, 18(1):1–13, January 2008.